

1. Introducción (8%)	Nota	Observaciones
a. Presenta breve investigación sobre la EMMET (definición, población objetivo, dominio/clasificación), con citas bibliográficas directas al DANE; b. Define correctamente qué es industria manufacturera y en cuántos grupos/dominios se clasifica, y explica la diferencia entre producción/ventas nominales y reales; c. Define la EMMET y los indicadores construidos con base en ella; d. Define el subdominio o clase industrial de la serie asignada según CIU Rev.4 A.C. (2022); e. Presenta y explica correctamente la ecuación DANE del número índice asignado, explicando cada variable que involucra; f. Ejemplifica correctamente, con el valor de la serie en una fecha dada, cómo se interpretan los valores del índice asignado; g. Define correctamente la variable asociada a la serie, su unidad de medida, período observado, frecuencia, N total de observaciones y fuente de los datos.	3,7	Se definen correctamente la industria manufacturera y los 39 dominios EMMET, la diferencia entre producción/ventas nominal y real, la EMMET y sus indicadores, la ecuación del número índice (con ejemplos numéricos interpretados en dos fechas distintas) y la variable, unidad de medida, período, N y fuente de la serie. Sin embargo, el dominio y las clases CIU reportados (agrupación de códigos 2020, 2023 y 2100, incluyendo productos farmacéuticos de la División 21) no corresponden al dominio EMMET asignado a esta serie, que agrupa clases exclusivamente de la División 20 (fabricación de sustancias y productos químicos); esto afecta la identificación correcta del subdominio/clase CIU pedida en el literal (d). Adicionalmente, el texto no incluye citas bibliográficas directas dentro de la redacción (solo un listado de referencias al final), por lo que no queda claro de qué fuente proviene cada afirmación específica.
2. Análisis descriptivo general y Modelos propuestos (12%)	Nota	Observaciones
a. Presenta y analiza correctamente la gráfica de la serie (o su logaritmo si es multiplicativa) y argumenta el tipo de componentes según la Tabla asignada; b. Presenta y analiza correctamente la componente de tendencia filtrada en la escala apropiada, identificando ciclos y posibles cambios estructurales; c. Justifica la presencia de componente estacional y si su forma es constante en el tiempo; presenta y analiza los boxplots comparativos; d. Presenta y analiza correctamente la ACF muestral (m=36) concluyendo sobre estacionariedad y sobre efectos de tendencia/estacionalidad en el patrón de la ACF; e. Diligencia correctamente la tabla del Apéndice (análisis descriptivo: serie y sus diferencias), evaluando media constante, varianza constante y ergodicidad (parte regular vs. estacional) en cada paso, y concluye sobre órdenes de diferencia necesarios; f. Test HEGY: plantea correctamente el modelo AR y el modelo de regresión asociados, enuncia las siete pruebas (H0, H1, frecuencia angular y período de cada raíz), reporta estadístico y valor P sobre la serie recortada y concluye correctamente sobre raíces unitarias regulares/estacionales, confrontando con el análisis anterior; g. Presenta correctamente las ecuaciones teóricas de los tres modelos propuestos (Modelo 1, 2 y 3) con sus supuestos estadísticos, sin cambiar la designación de los modelos indicados en las tablas asignadas.	4,5	El análisis gráfico de la serie y su logaritmo, la componente de tendencia filtrada, los boxplots mensuales y la ACF muestral (m=36) están bien presentados y argumentados, con conclusiones coherentes sobre no estacionariedad y presencia de componente estacional anual. La tabla de análisis descriptivo de la serie y sus diferencias está diligenciada para las cuatro versiones de la serie. El test HEGY está completo (modelo AR y regresión auxiliar planteados, las siete pruebas con H0/H1, frecuencia angular, ciclos, estadístico y valor P sobre la serie recortada) y su conclusión sobre d=D=1 es coherente con el análisis gráfico previo. Las ecuaciones teóricas completas de los tres modelos con sus supuestos no se consolidan en esta sección como lo pide el enunciado, sino que se presentan de forma dispersa a lo largo del documento y solo se reúnen en la tabla comparativa final.
3. Modelo 1: ajuste local (15%)	Nota	Observaciones
a. Formulación teórica correcta del modelo indicado (SEHW o Descomposición & LOESS) con los supuestos estadísticos del término de error; b. Ajuste con validación cruzada (n=271, m=12): si el Modelo 1 es SEHW, presenta correctamente la tabla resumen del ajuste SEHW; si el Modelo 1 es Descomposición & LOESS, presenta la tabla de estimación de los efectos estacionales, y presenta y analiza correctamente los resultados del ajuste loess sobre la serie desestacionalizada, informando e interpretando el parámetro de suavizamiento (span) óptimo y el número de parámetros equivalentes loess, junto con la gráfica del ajuste loess sobre la serie desestacionalizada; presenta y analiza también la gráfica de la estimación de la estacionalidad, comparándola con el patrón estacional observado; c. Presenta correctamente la ecuación ajustada, la gráfica de ajuste y el AIC/BIC (exp(C*n(p))); si aplica, reporta la fórmula y el valor del factor de corrección lognormal; d. Análisis de residuales diligenciando únicamente la tabla del Apéndice Modelo 1 (evaluación de residuos): concluye correctamente sobre media cero, varianza constante y patrones (ciclos/rachas) en los residuos; e. Pronósticos para la validación cruzada: da la ecuación de los pronósticos puntuales, presenta e interpreta correctamente las tablas de pronósticos puntuales/I.P., la gráfica comparativa, y las medidas MAE, MAPE, RMSE, amplitud media, cobertura y score promedio de los I.P.	4,5	La tabla de estimación de los efectos estacionales, el span óptimo por AICC, el número de parámetros equivalentes loess y su interpretación (ajuste casi interpolador) están correctamente presentados y analizados, al igual que la gráfica del ajuste loess sobre la serie desestacionalizada y de la estacionalidad estimada, comparándola apropiadamente con el patrón de los boxplots. El AIC/BIC de este modelo se presenta, pero en una tabla que ya incluye también el AIC/BIC del Modelo 2 antes de que este haya sido introducido en el documento, en vez de reportarse de forma autónoma en esta sección. La formulación teórica completa del modelo (ecuación con la componente de tendencia, estacional y de error, junto con los supuestos del error) no se presenta en esta sección; solo aparece consolidada en la tabla comparativa del numeral 6. El análisis de residuales (varianza no constante, patrón en ACF/PACF, Ljung-Box rechazado en todo m) es correcto y consistente con las gráficas de residuales mostradas. Los pronósticos puntuales, su ecuación, los intervalos del 95% y su interpretación están bien presentados.
4. Modelo 2: regresión global con error estructural ARMA (25%)	Nota	Observaciones
a. Formulación teórica correcta (misma estructura de tendencia y estacionalidad, error ARMA) con sus supuestos; b. Identificación del error estructural: formula correctamente el test Durbin-Watson (modelo de regresión, p(1), H0, H1, estadístico, criterio de decisión); presenta gráficas de residuos y formula completas las pruebas ACF/PACF (m=36) y Ljung-Box (m=6,12,...,36); presenta las conclusiones únicamente en la tabla del Apéndice D (Modelo 2); c. Identificación de modelos ARMA provisionales con ACF-PACF, EACF (print-screen con triángulo de ceros trazado) y auto.arima() (print-screen variando ic="aic"/"bic"); da correctamente la ecuación de cada modelo identificado; presenta el análisis únicamente en la tabla del Apéndice E (Modelo 2); d. Ajuste con validación cruzada: tabla de parámetros estimados debidamente editada, gráfica de ajuste, ecuación ajustada y AIC/BIC; si aplica, reporta el factor de corrección lognormal; e. Tabula, grafica e interpreta correctamente los parámetros estacionales estimados ($\hat{\sigma}$ o $\exp(\hat{\sigma}) \times 100\%$) usando interpdeltas(); f. Formula y realiza correctamente los tests de significancia de tendencia, estacionalidad y parámetros del error ARMA, presentando las conclusiones únicamente en la tabla del Apéndice F (Modelo 2); g. Análisis de residuales de ajuste (a_t): gráficas, pruebas ACF/PACF/Ljung-Box y normalidad (solo si no hay correlaciones) formuladas de forma completa (H0, H1, estadístico, criterio); conclusiones presentadas únicamente en la tabla del Apéndice G (Modelo 2); h. Pronósticos para la validación cruzada: presenta, interpreta y analiza correctamente la ecuación de los pronósticos puntuales con origen en n=271, los pronósticos puntuales y por intervalos del 95%, y la gráfica comparativa.	4	El test de Durbin-Watson está completo y correctamente formulado (modelo de regresión para Et, p(1), H0/H1, estadístico, criterio de decisión), y la tabla de ruido blanco/estacionariedad del error estructural (patrones, rechazos ACF/PACF, Ljung-Box) es coherente con la conclusión de que Et no es ruido blanco pero sí es apto para modelación ARMA. Sin embargo, la identificación de modelos ARMA provisionales solo presenta el print-screen de auto.arima() variando el criterio de información; no se incluye el print-screen de la EACF con el triángulo de ceros trazado, ni se presenta la ecuación explícita de cada modelo identificado por los distintos métodos, quedando la identificación reducida a una descripción narrativa general. La tabla de parámetros estimados del error AR(15), la ecuación ajustada en escala original y el factor de corrección lognormal están correctamente presentados. No se incluye una tabla ni una gráfica de los efectos estacionales estimados ($\hat{\sigma}$ o su versión exponenciada $\times 100\%$) para este modelo; su interpretación queda limitada a una frase general sin respaldo tabular o gráfico. Los tests de significancia de tendencia, estacionalidad y parámetros del error están completos y bien resumidos en la tabla de conclusiones. El análisis de residuales de ajuste (ACF, PACF, Ljung-Box, normalidad) es correcto y coherente con la conclusión de que el modelo valida ruido blanco pero no normalidad. El AIC/BIC y las medidas de precisión de este modelo no se presentan dentro de esta sección, sino que se difieren por completo a secciones posteriores.
5. Modelo 3: SARIMA (20%)	Nota	Observaciones

a. Identificación (ejercicio metodológico): examina correctamente ACF-PACF ($m=36$) de la serie diferenciada según d, D indicados, distinguiendo parte regular ($k=1, \dots, 6$) y estacional ($k=12, 24, 36$), patrón cola/corte; diligencia únicamente la tabla del Apéndice J (Modelo 3); b. Presenta print-screen de las seis corridas de <code>auto.arima()</code> (combinaciones $ic \times seasonal.test$), da las ecuaciones de los modelos resultantes y concluye correctamente si son candidatos apropiados; c. Da la ecuación teórica correcta del modelo SARIMA (para Y_t o $\log(Y_t)$) con notación completa de polinomios y diferencias, con o sin deriva según corresponda; d. Ajuste con validación cruzada usando el modelo de la Tabla asignada (método ML u otro indicado); presenta la tabla de parámetros con <code>coefest()</code>; evalúa correctamente la significancia ($Z0 \sim N(0,1)$); compara el ajuste por gráfica y por AIC/BIC; no reporta ecuación ajustada; e. Análisis de residuales: gráficas, pruebas ACF/PACF, Ljung-Box ($m=36$) y normalidad (si aplica) formuladas de forma completa; conclusiones presentadas únicamente en la tabla del Apéndice K (Modelo 3); f. Pronósticos para la validación cruzada: tablas de pronósticos puntuales/I.P., medidas de precisión, interpretación y gráfica comparativa (no reporta ecuación de pronóstico).	4	La identificación con ACF-PACF de la serie diferenciada (distinguiendo parte regular y estacional, patrón cola/corte) está correctamente diligenciada y es consistente con el modelo ARIMA(0,1,1)(0,1,1)[12] propuesto por este método. Se presentan las seis corridas de <code>auto.arima()</code> (AIC/BIC combinados con tres pruebas de raíz unitaria estacional), pero la tabla que resume sus ecuaciones contiene inconsistencias en el orden de los modelos identificados con los criterios BIC y SEAS frente a lo que muestra la salida de consola de la propia figura: falta el término MA regular en el modelo del criterio BIC, y el orden de la parte MA reportado para los modelos del criterio SEAS no coincide con el que arroja la consola. Esta inconsistencia lleva a una conclusión imprecisa sobre qué tan similar es alguno de los modelos identificados al modelo SARIMA finalmente asignado para ajustar. La ecuación teórica del Modelo 3, con notación completa de polinomios y diferencias y sin deriva, está correctamente presentada y justificada. La tabla de parámetros con <code>coefest()</code> está completa y evalúa la significancia bajo la distribución correspondiente, aunque no se indica explícitamente en el texto qué método de optimización se usó para el ajuste. El análisis de residuales y los pronósticos (sin reportar la ecuación de pronóstico, como corresponde) están correctamente presentados e interpretados. Igual que en el Modelo 2, el AIC/BIC y las medidas de precisión de este modelo no aparecen dentro de su propia sección.
6. Comparación de los tres modelos y selección del mejor (10%) a. Presenta las ecuaciones teóricas de los tres modelos (Modelo 1, 2 y 3), pudiendo organizarlas en una tabla resumen; b. Presenta una única tabla con medidas de ajuste, cobertura, amplitud media y score promedio de los I.P., y medidas de precisión de pronósticos puntuales (MAE, MAPE, RMSE), todo en la escala original de los datos, para los tres modelos; c. Presenta una gráfica comparativa de los pronósticos puntuales de los tres modelos junto con los valores reales de la serie; d. Presenta una tabla resumen (sin gráficos de residuos, ACF ni PACF) indicando, para cada modelo, la validez del supuesto "error de ajuste ruido blanco" (sí/no) y del supuesto "error de ajuste distribuye normal" (sí/no/NA); e. Da una conclusión final justificada sobre qué tipo de modelación (global vs. local, con o sin estructura ARMA/SARIMA) se aproxima mejor a la dinámica de la serie, teniendo en cuenta validez de supuestos, calidad de ajuste y calidad de pronósticos.	Nota 4,6	Observaciones Se presentan de forma clara las ecuaciones teóricas de los tres modelos en una tabla resumen, una única tabla con los criterios de información, las medidas de precisión de pronóstico puntual y las medidas por intervalos (amplitud, cobertura, score) de los tres modelos en la escala original de los datos, la gráfica comparativa de los pronósticos puntuales frente a los valores reales, y una tabla resumen de la validez de los supuestos de ruido blanco y normalidad para cada modelo. La conclusión final sobre la preferencia por la modelación global con error ARMA frente a la modelación local y la modelación SARIMA está bien argumentada, considerando de forma conjunta la validez de los supuestos, la calidad del ajuste y la calidad de los pronósticos.
7. Conclusiones finales (10%) a. Presenta un resumen breve de los principales resultados encontrados desde el análisis descriptivo hasta el ajuste y pronóstico de los tres modelos; b. Enuncia los principales problemas enfrentados en la modelación de los patrones de la serie (validez de supuestos, atipicidades, cambios estructurales u otros aspectos relevantes); c. Indica cuál es el mejor modelo, coherente con lo concluido en la comparación, dando prioridad a los resultados de análisis de residuos, de pronósticos y de ajustes, en ese orden; d. Argumenta qué logró capturar el mejor modelo con relación a la dinámica de la serie (tendencia, estacionalidad, variaciones cíclicas) y qué críticas o limitaciones tiene; e. Argumenta sobre la confiabilidad de los pronósticos de ese modelo.	Nota 4,3	Observaciones El resumen de los resultados principales, el planteamiento de los problemas enfrentados en la validación de supuestos, la identificación coherente del mejor modelo (consistente con la comparación del numeral anterior) y el argumento sobre qué logró capturar de la dinámica de la serie y sobre la confiabilidad de sus pronósticos están bien desarrollados. No obstante, en la tabla resumen que se repite al inicio de esta sección, la fórmula del error de ajuste reportada para los modelos Global con error ARMA y SARIMA aparece en la escala original de la serie, en lugar de la escala logarítmica que se había establecido correctamente en la sección de análisis de residuales; esta inconsistencia interna debería corregirse.
	Nota	4,2

Modelos de Componentes versus Modelos ARIMA-SARIMA

Juan Pablo Pérez Álvarez, Sara Restrepo Gil, Nicolás Ruiz Blandón y Estefanía Zapata Solís

Fecha de entrega: 02 – 08 – 2026

1. Introducción

Según el DANE, la industria manufacturera comprende el conjunto de actividades de transformación física y química de materiales, sustancias o componentes en productos nuevos, ya sea que el trabajo se efectúe con máquinas o a mano. En la Clasificación Industrial Internacional Uniforme Rev. 4 adaptada para Colombia (CIIU Rev. 4 A.C.) corresponde a la Sección C, divisiones 10 a 33. En el marco de la EMMET la industria se representa mensualmente mediante 39 dominios, que son agrupaciones de clases CIIU Rev. 4 A.C. asociadas a las actividades económicas del sector fabril.

La Encuesta Mensual Manufacturera con Enfoque Territorial (EMMET) es la investigación con la que el DANE obtiene información sobre la evolución de corto plazo de las principales variables económicas del sector manufacturero colombiano: producción, ventas, empleo, sueldos y horas trabajadas, a nivel del total nacional y por departamentos, áreas metropolitanas y ciudades. Es una operación de tipo encuesta por muestreo no probabilístico, de corte. Con base en ella se construyen los índices de producción nominal y real, de ventas nominal y real, y de empleo total y por área funcional, todos enlazados y con base 2018 = 100.

Los índices nominales miden la producción o las ventas a precios corrientes del período observado, de modo que incorporan tanto el cambio real de las cantidades como el efecto de la variación de precios. Los índices reales se expresan a precios constantes del año base: se deflactan con un índice de precios para remover el efecto inflacionario, de manera que reflejan solo el cambio en el volumen físico producido o vendido. La diferencia entre ambos es el componente de precios.

La serie analizada corresponde al dominio EMMET rotulado “Fabricación de otros productos químicos”, código 2020 en el anexo. Según la nota (d) del propio archivo de datos, este dominio agrupa los dominios 2020, 2023 y 2100 de la CIIU Rev. 4 A.C., pertenecientes a la División 20, fabricación de sustancias y productos químicos, y a la División 21, farmacéuticos. Incluye la fabricación de otros productos químicos n.c.p. (clase 2029: anticorrosivos, neutralizadores, desengrasantes, aditivos, aceites y grasas modificados químicamente, anticongelantes), jabones, detergentes, perfumes y preparados de tocador (2023), y productos farmacéuticos, sustancias químicas medicinales y productos botánicos de uso farmacéutico (2100).

Un número índice es una medida estadística que compara una magnitud simple o compleja entre dos momentos o lugares, tomando uno de ellos como referencia o base. Según el tipo de comparación se distinguen dos familias. Los índices simples comparan una única magnitud entre dos períodos y pueden ser en serie, cuando la referencia es fija en el tiempo ($I_0^t(X) = X_t/X_0 \times 100$), o en cadena, cuando la referencia es el período inmediatamente anterior ($IC^t = X_t/X_{t-1} \times 100$). Los índices complejos combinan varias magnitudes o componentes en una sola medida y pueden ser no ponderados, cuando se promedian los índices simples de cada componente con igual peso, o ponderados, cuando a cada componente se le asigna un coeficiente de importancia relativa w_i antes de promediar.

La variable analizada es un índice simple en serie, con base fija 2018 = 100 y enlace de series entre los distintos empalmes metodológicos de la EMMET. Corresponde al índice de producción nominal de este dominio, un número índice adimensional. Para cada mes t se calcula como

$$I_t = \frac{V_t}{\bar{V}_{2018}} \times 100,$$

donde V_t es el valor de la producción del dominio a precios corrientes en el mes t y $\bar{V}_{2018}$ es el valor promedio mensual de la producción del dominio en el año base 2018, con enlace de series.

Un valor del índice igual a 100 equivale al nivel promedio mensual de 2018. Por encima de 100 indica un nivel superior y por debajo, inferior. El valor de enero de 2001, igual a 33,2, significa que la producción nominal del dominio en ese mes fue el 33,2 % del promedio mensual de 2018. El valor de julio de 2024, cercano a 162, indica que la producción nominal fue cerca de 1,62 veces ese promedio, es decir un 62 % superior.

La serie es mensual, va de enero de 2001 a julio de 2024 y tiene $N = 283$ observaciones. La muestra de ajuste abarca de enero de 2001 a julio de 2023 ($n = 271$) y la de validación cruzada de agosto de 2023 a julio de 2024 ($m = 12$). Fuente: DANE, EMMET.

2. Análisis descriptivo de la serie y modelos propuestos

Considere la serie del índice de producción nominal mensual del dominio EMMET “Fabricación de otros productos químicos”, que inicia en enero de 2001 y finaliza en julio de 2024, ilustrada en la Figura 1. Se desea ajustar la serie e implementar la estrategia de

validación cruzada así: ajuste con los primeros $n=271$ datos, es decir, hasta julio de 2023, y pronósticos ex-post para los últimos $m=12$ datos, que corresponden al período comprendido entre agosto de 2023 y julio de 2024.




Figura 1: (a) Serie del índice de producción nominal de "Fabricación de otros productos químicos"; (b) logaritmo natural de la serie.




Figura 2: Gráfica Boxplot mensual de la serie, **Figura 3:** Gráfica de la Tendencia del logaritmo de la serie

Del análisis gráfico de la Figura 1(a) se observa que la serie presenta una tendencia creciente con varianza heterocedástica, lo que indica una componente multiplicativa. Esto se confirma en la Figura 1(b), donde la transformación logarítmica estabiliza la varianza. En la Figura 2, la tendencia extraída sobre el logaritmo de la serie muestra un crecimiento moderado entre 2001 y 2020, seguido de una aceleración marcada entre 2021 y 2023, posiblemente asociada a los efectos de la pandemia y la post pandemia, para luego presentar una ligera estabilización. Los periodos de crecimiento sostenido sugieren la presencia de una componente cíclica, mientras que el cambio abrupto observado corresponde a un cambio estructural. En conjunto, este comportamiento indica que la tendencia es más adecuada para un modelamiento local. Por su parte, en la Figura 3 la componente estacional exhibe un patrón periódico prácticamente constante, con niveles sistemáticamente más bajos en enero y diciembre y más altos entre marzo y septiembre, presentando algunas irregularidades propias de la variabilidad introducida por la tendencia, por lo que resulta apropiado un modelamiento global para esta componente.

2.1. Análisis de la ACF estimada de la serie




Figura 4: Gráfica ACF estimada de la serie

En la Figura 4 se observa que la ACF presenta un decaimiento lento, con autocorrelaciones positivas y significativas incluso para rezagos altos. Esto, junto con la tendencia creciente de la serie, indica que la media no es constante y, por tanto, la serie no es estacionaria. Asimismo, al no decaer rápidamente hacia cero, la ACF evidencia que la serie no presenta un comportamiento ergódico. Los ligeros repuntes en los rezagos 12, 24 y 36 reflejan la presencia de una componente estacional anual.

2.3. Análisis de ACF de la serie recortada y sus diferencias




Figura 5: (a) Serie recortada $\text{Log}(Y_t)$, (b) $\nabla \text{Log}(Y_t)$, (c) $\nabla 12 \text{Log}(Y_t)$, (d) $\nabla \nabla 12 \text{Log}(Y_t)$




Figura 6: (a) ACF Serie recortada $\text{Log}(Y_t)$, (b) ACF $\nabla \text{Log}(Y_t)$, (c) ACF $\nabla 12 \text{Log}(Y_t)$, (d) ACF $\nabla \nabla 12 \text{Log}(Y_t)$

Tabla 1: Análisis descriptivo de la serie y sus diferencias

Análisis de la serie $\log(Y_t)$ y sus diferencias para determinar órdenes d , D de filtros diferencias regular y estacional necesarios					
			Análisis ACF		
			Parte Regular ($K=1,2,3,4,5,6i$)	Parte estacional ($K=12,24,36$)	
serie	Media cte. (sí, no, por qué)	Varianza cte (sí, no)	¿parte regular es ergódica? (sí, no y patrón)	¿parte estacional es ergódica? (sí, no y patrón)	¿Proceso es estacionario? (sí, no)

$\log(Y_t)$	No, por la presencia de tendencia y estacionalidad periódica casi exacta que conjuntamente cambian la media.	Sí	No, se evidencia cola positiva con síntoma de raíz unitaria regular por decaimiento lento	No, se evidencia cola positiva de periodo 12 con síntoma de raíz unitaria estacional	No
$\nabla \log(Y_t)$	No, aunque la serie tiene nivel estable, la media se ve afectada por patrón estacional periódica casi exacto.	Sí	Sí, se evidencia corte en $K = 2$	No, se evidencia cola positiva de periodo 12 con síntoma de raíz unitaria estacional	No
$\nabla_{12} \log(Y_t)$	No, a pesar de no mostrar estacionalidad periódica exacta, no tiene nivel estable	No	No, se evidencia cola positiva con síntoma de raíz unitaria regular por decaimiento lento	Sí, se evidencia corte en $K=0$	No
$\nabla \nabla_{12} \log(Y_t)$	Sí, el nivel es estable y no muestra estacionalidad periódica exacta o casi exacta	Sí	Corte no nulo en $K=1$	Sí, se evidencia corte	Sí

Conclusión: ¿cómo se debe diferenciar a la serie $\log(Y_t)$ para transformarla a un proceso estacionario?:

Primero se debe aplicar diferencia regular para estabilizar el nivel y hacer ergódica la parte regular, luego aplicamos la diferencia estacional para hacer ergódica la parte estacional. Por lo tanto, se requiere combinar ambos filtros: $W_t = \nabla \nabla_{12} \log(Y_t)$ para llegar a un proceso estacionario.

2.4. Test de HEGY sobre la serie recortada a n=271

Como la serie presenta una componente estacional multiplicativa (ver sección de análisis descriptivo), el test HEGY se aplica sobre el logaritmo de la serie recortada,

$$W_t = \log(Y_t), \quad t = 1, \dots, 271.$$

Se supone que W_t admite una representación autorregresiva de orden infinito, $AR(\infty)$:

$$\phi(B) W_t = \varepsilon_t, \quad \phi(B) = 1 - \sum_{i=1}^{\infty} \phi_i B^i, \quad \sum_{i=1}^{\infty} \phi_i^2 < \infty,$$

donde $\{\varepsilon_t\}_{t \in \mathbb{Z}}$ es un ruido blanco $\varepsilon_t \sim N(0, \sigma^2)$. La regresión auxiliar de HEGY para datos mensuales ($s = 12$) es:

$$\begin{aligned} \nabla_{12} W_t = & \pi_1 X_{1,t-1} + \pi_2 X_{2,t-1} + \pi_3 X_{3,t-1} + \pi_4 X_{3,t-2} \\ & + \pi_5 X_{4,t-1} + \pi_6 X_{4,t-2} + \pi_7 X_{5,t-1} + \pi_8 X_{5,t-2} \\ & + \pi_9 X_{6,t-1} + \pi_{10} X_{6,t-2} + \pi_{11} X_{7,t-1} + \pi_{12} X_{7,t-2} \\ & + \sum_{i=1}^{p-1} b_i \nabla_{12} W_{t-i} + \varepsilon_t, \end{aligned}$$

donde $\nabla_{12} = 1 - B^{12}$ y las variables auxiliares $X_{j,t}$ se construyen a partir de W_t como:

$$\begin{aligned} X_{1,t} &= (1+B)(1+B^2)(1+B^4+B^8) W_t \\ X_{2,t} &= -(1-B)(1+B^2)(1+B^4+B^8) W_t \\ X_{3,t} &= -(1-B^2)(1+B^4+B^8) W_t \\ X_{4,t} &= -(1-B^4)(1-\sqrt{3}B+B^2)(1+B^4+B^8) W_t \\ X_{5,t} &= -(1-B^4)(1+\sqrt{3}B+B^2)(1+B^4+B^8) W_t \\ X_{6,t} &= -(1-B^4)(1-B^2+B^4)(1-B+B^2) W_t \\ X_{7,t} &= -(1-B^4)(1-B^2+B^4)(1+B+B^2) W_t \end{aligned}$$

El número de rezagos $p-1$ de $\nabla_{12} W_{t-i}$ se elige de modo que los residuales de la regresión auxiliar sean ruido blanco.

Tabla 2: Resultados y conclusiones Test HEGY

Test	Hipótesis	Frecuencia Angular (θ)	Ciclos	Estadístico	Valor P	Decisión Sobre H_0	Conclusiones
1	$H_0: \pi_1 = 0$ (Hay raíz unitaria regular) $H_1: \pi_1 < 0$ (No hay raíz unitaria regular)	0	0	3.9728	0.10	No se rechaza H_0	Hay raíz unitaria regular
2	$H_0: \pi_2 = 0$ (Hay raíz unitaria estacional bimensual) $H_1: \pi_2 < 0$ (No hay raíz unitaria estacional bimensual)	π	6	-2.7013	0.01	Se rechaza H_0	No hay raíz unitaria estacional bimensual o en la frecuencia angular π
3	$H_0: \pi_3 = \pi_4 = 0$ (Hay raíz unitaria estacional cuatrimestral) $H_1: \pi_3 < 0$ (No hay raíz unitaria estacional cuatrimestral)	$\pm \frac{\pi}{2}$	3	1.8072	0.10	No se rechaza H_0	Hay raíz unitaria estacional cuatrimestral o en la frecuencia angular $\pm \frac{\pi}{2}$

	$H1: \pi_3 < 0 \text{ ó } \pi_4 \neq 0$ (No hay raíz unitaria estacional cuatrimestral)						
4	$H0: \pi_5 = \pi_6 = 0$ (Hay raíz unitaria estacional trimestral) $H1: \pi_5 < 0 \text{ ó } \pi_6 \neq 0$ (No hay raíz unitaria estacional trimestral)	$\pm \frac{2\pi}{3}$	4	3.2411	0.0425	Se rechaza H_0	No hay raíz unitaria estacional trimestral o en la frecuencia angular $\pm \frac{2\pi}{3}$
5	$H0: \pi_7 = \pi_8 = 0$ (Hay raíz unitaria estacional semestral) $H1: \pi_7 < 0 \text{ ó } \pi_8 \neq 0$ (No hay raíz unitaria estacional semestral)	$\pm \frac{\pi}{3}$	2	0.8534	0.10	No se rechaza H_0	Hay raíz unitaria estacional semestral o en la frecuencia angular $\pm \frac{\pi}{3}$
6	$H0: \pi_9 = \pi_{10} = 0$ (Hay raíz unitaria estacional de 5 ciclos por año) $H1: \pi_9 < 0 \text{ ó } \pi_{10} \neq 0$ (No hay raíz unitaria estacional de 5 ciclos por año)	$\pm \frac{5\pi}{6}$	5	16.5704	0.01	Se rechaza H_0	No Hay raíz unitaria estacional de 5 ciclos por año o en la frecuencia angular $\pm \frac{5\pi}{6}$
7	$H0: \pi_{11} = \pi_{12} = 0$ (Hay raíz unitaria estacional anual) $H1: \pi_{11} < 0 \text{ ó } \pi_{12} \neq 0$ (No hay raíz unitaria estacional anual)	$\pm \frac{\pi}{6}$	1	1.3019	0.10	No se rechaza H_0	Hay raíz unitaria estacional anual en la frecuencia angular $\pm \frac{\pi}{6}$

Bajo el análisis gráfico y el test HEGY, se llega a la conclusión de que se requiere usar la combinación del filtro de diferencia regular $\nabla d = (1 - B)d$ en por lo menos $d=1$ y por raíces unitarias estacionales se requiere usar filtro $\nabla D = (1 - B^12)D$ en por lo menos $D=1$, esto para que el proceso resultante sea ergódico debido a la eliminación de las raíces unitarias regulares y estacionales presentes.

2.5 Identificación del error estructural E_t del Modelo 2

Antes de ajustar el error AR(15) indicado en la Tabla 3, se evalúa el supuesto de ruido blanco sobre los errores estructurales $\hat{E}_t$ del modelo de regresión global sin estructura ARMA. Este ejercicio es de práctica metodológica: el modelo que finalmente se ajusta es el asignado, que puede no coincidir con el identificado aquí.

2.5.1 Test de Durbin-Watson

Sobre los errores estructurales se postula $E_t = \rho(1) E_{t-1} + u_t$, con u_t ruido blanco, donde $\rho(1)$ es la autocorrelación de orden 1 de $\{E_t\}$.

Las hipótesis son $H_0: \rho(1) = 0$, errores incorrelacionados, frente a $H_1: \rho(1) > 0$, autocorrelación positiva de orden 1. El estadístico de prueba es

$$d = \frac{\sum_{t=2}^n (\hat{E}_t - \hat{E}_{t-1})^2}{\sum_{t=1}^n \hat{E}_t^2} \approx 2(1 - \hat{\rho}(1)),$$

que toma valores en $[0,4]$, donde los valores cercanos a 0 indican autocorrelación positiva. Se rechaza H_0 si el valor p es menor a 0,05.

El resultado es $\hat{\rho}(1) = 0,551$, $d = 0,896$ y valor $p = 0,000$. Se rechaza H_0 : hay evidencia fuerte de autocorrelación positiva de orden 1, de modo que los errores estructurales no son ruido blanco.

2.5.2 Gráficas de los errores estructurales

FACT?




Figura 7: Errores estructurales $\hat{E}_t$ del modelo global contra el tiempo.




Figura 8: (a) ACF y (b) PACF de los errores estructurales $\hat{E}_t$, $m = 36$, con límites de Bartlett.

2.5.3 Ruido blanco y estacionariedad de E_t

Tabla 3. Supuesto de ruido blanco y estacionariedad del error estructural E_t .

Varianza cte.	Medi a cero	Patrones contra la independencia	Rechazos ACF (k)	Rechazos PACF (k)	Rechazos Ljung-Box (m)	¿Ruido blanco?
Sí	Sí	Sí: decaimiento lento, ciclos y rachas, indican autocorrelación positiva	1 a 9, 11	1, 2, 3, 9, 14, 15, 24	6, 12, 18, 24, 30, 36, todos con $p \approx 0$	No
¿Estacionario en varianza?	¿Estacionario en media?		¿Ergódico?		Conclusión	
Sí	Sí		Sí		E_t es estacionario, ergódico y de media cero, pero no ruido blanco, así que es apto para modelación ARMA	

2.5.4 Salidas de consola

```

Series: Et
ARIMA(1,0,1) with zero mean

Coefficients:
      ar1      ma1
      0.8874  -0.5384
s.e.   0.0419   0.0794

sigma^2 = 0.002725: log likelihood = 416.33
AIC=-826.65 AICc=-826.56 BIC=-815.85
Series: et.ts
ARIMA(3,0,2)(2,0,0)[12] with zero mean

Coefficients:
      ar1      ar2      ar3      ma1      ma2      sar1      sar2
      -0.2118  0.7499  0.1304  0.5520  -0.3700  0.1418  -0.1044
s.e.   0.1912  0.0923  0.1242  0.1905  0.1877  0.0650  0.0670

sigma^2 = 0.00268: log likelihood = 420.87
AIC=-825.74 AICc=-825.19 BIC=-796.93

Series: Et
ARIMA(1,0,1) with zero mean

Coefficients:
      ar1      ma1
      0.8874  -0.5384
s.e.   0.0419   0.0794

sigma^2 = 0.002725: log likelihood = 416.33
AIC=-826.65 AICc=-826.56 BIC=-815.85
Series: et.ts
ARIMA(1,0,1) with zero mean

Coefficients:
      ar1      ma1
      0.8874  -0.5384
s.e.   0.0419   0.0794

sigma^2 = 0.002725: log likelihood = 416.33
AIC=-826.65 AICc=-826.56 BIC=-815.85

```

Figura 8: Salida de consola de auto.arima() aplicada a $\hat{E}_t$, sobre el vector de residuales y sobre el objeto ts, con ic = "aic" e ic = "bic".

Todos los modelos automáticos son estacionarios, con $d=0$ y $D=0$, y de media cero, así que son candidatos válidos. Ninguno coincide con el AR(15) que finalmente se ajusta según la Tabla 3, que resulta de una depuración posterior donde se verificó ruido blanco e invertibilidad, tal como advierte la guía.

2.6 Identificación de modelos SARIMA(p,d,q) × (P,D,Q)[12]:

Se presentan los modelos identificados a través de las funciones `armasubsets()` sobre $\nabla \nabla_{12} \text{Log}(Y_t)$, `auto.arima()` sobre $\text{Log}(Y_t)$ y el análisis de las gráficas de la ACF y PACF de $\nabla \nabla_{12}(Y_t)$ (Figura). Los resultados que se presentan en este último método de identificación no serán tenidos en cuenta a la hora de ajustar y pronosticar.




Figura 9: (a) ACF muestral de $\nabla \nabla_{12} \text{Log}(Y_t)$ (b) PACF muestral de $\nabla \nabla_{12} \text{Log}(Y_t)$

Tabla 4: Identificación sobre $W_t = \nabla \nabla_{12} \log(Y_t)$, el logaritmo de la serie recortada a $n = 271$ y filtrada con una diferencia regular ($d = 1$) y una estacional ($D = 1$)

1. Identificación sobre W_t = (defina aquí quién es W_t)					
Parte Regular			Parte Estacional		
Evaluada en k (valores de k)	Patrón ACF: ¿cola? indique el tipo; ¿corte? indique en cuales k es no nulo	Patrón PACF: ¿cola? indique el tipo; ¿corte? indique en cuales k es no nulo	Evaluada en k (valores de k)	Patrón ACF: ¿cola? indique el tipo; ¿corte? indique en cuales k es no nulo	Patrón PACF: ¿cola? indique el tipo; ¿corte? indique en cuales k es no nulo
$k= 1, 2, 3, 4, 5, 6$	Corte no nulo en $k= 1$	Cola negativa	$K= 12, 24, 36$	Corte no nulo en $k= 12$	Cola negativa con periodo 12
Nombre modelo ARMA(p,q) identificado parte regular de W_t : ARMA(0,q), con $q= 1$ MA(1)			Nombre modelo ARMA(P,Q)[12] identificado en parte estacional de W_t : ARMA (0,Q) [12] con $Q= 1$ MA(1)		
2. Modelo ARIMA(p,d,q)(P,D,Q)[12] para $\log Y_t$ dé su ecuación con supuestos:					
es un ARIMA(0,1,1)(0,1,1)[12] sin deriva					
$\nabla \nabla_{12} \log(Y_t) = \theta_q(B)\theta_Q(B^{12})E_t, \text{ con } \{E_t\}_{t \in \mathbb{Z}} + Un\text{ RB} \sim N(0, \sigma^2)$					
$(1-B)(1-B^{12})\log(Y_t) = (1+\theta_1 B)(1+\theta_1 B^{12})E_t, \text{ con } \{E_t\}_{t \in \mathbb{Z}} + Un\text{ RB} \sim N(0, \sigma^2)$					




Figura 7: Resultados método `auto.arima` usando criterio AIC (arriba) y BIC (abajo) con `seasonal.test`: (a) ocsb; (b) ch; (c) seas

Tabla 5. Ecuaciones de modelos ARIMA(p,d,q)(P,D,Q)[12] para Y_t identificados por métodos `auto.arima`

Modelo	Test Seasonal	Criterio	Ecuación
A	OCSB CH	AIC AIC	Y_t es un ARIMA(5,1,0)(2,0,0)[12] Sin deriva $(1 - \phi_1 B - \phi_2 B^2 - \phi_3 B^3 - \phi_4 B^4 - \phi_5 B^5)(1 - \Phi_1 B^{12} - \Phi_2 B^{24})(1 - B)\text{Log}(Y_t) = E_t$, con $\{E_t\}_{t \in \mathbb{Z}} + un\text{RB} \sim N(0, \sigma^2)$

B	OCSB CH	BIC BIC	Y_t es un ARIMA(3,1,0)(2,0,0)[12] $(1 - \phi_1 B - \phi_2 B^2 - \phi_3 B^3)(1 - \phi_1 B^{12} - \phi_2 B^{24})(1 - B) \text{Log}(Y_t) = Et$, con $\{Et\} t \in \mathbb{Z} + un R. B \sim N(0, \sigma^2)$
C	SEAS	AIC	Y_t es un ARIMA(1,1,4)(2,1,2)[12] Sin deriva $(1 - \phi_1 B)(1 - \phi_1 B^{12} - \phi_2 B^{24})(1 - B)(1 - B^{12}) \text{Log}(Y_t) = (1 + \theta_1 B + \theta_2 B^2 - \theta_3 B^3 - \theta_4 B^4)(1 + \theta_1 B^{12} + \theta_2 B^{24})Et$, con $\{Et\} t \in \mathbb{Z} + un R. B \sim N(0, \sigma^2)$
D	SEAS	BIC	Y_t es un ARIMA(0,1,1)(2,1,2)[12] Sin deriva $(1 - \phi_1 B^{12} - \phi_2 B^{24})(1 - B)(1 - B^{12}) \text{Log}(Y_t) = (1 + \theta_1 B)(1 + \theta_1 B^{12} + \theta_2 B^{24})Et$, con $\{Et\} t \in \mathbb{Z} + un R. B \sim N(0, \sigma^2)$

Los Modelos C y D cumplen con tener ambas diferencias $d=D=1$, por lo tanto pueden ser estacionarias al eliminar las raíces unitarias regulares y estacionales, por esta razón se podrían considerar como posibles modelos, aunque ninguno de ellos coincide con los cortes encontrados en la PACF y cuentan con parte SAR ambos y AR el modelo c. Comparándolos respecto al modelo proporcionado para ajustar (ARIMA(1,1,2)(2,1,2)[12]) vemos que justamente son estos 2 los más similares a este, sin ser ninguno de los modelo proporcionados por la función auto.arima el proporcionado para hacer el ajuste. Los modelos A y B son descartados por no aplicar la diferencia estacional y por ende, no eliminan las raíces unitarias estacionales, y como ya se pudo ver en el test de HEGY, estas existen, por consiguiente la serie no sera estacionaria.

3. Ajustes de modelos con validación cruzada

Los tres modelos se ajustan excluyendo los últimos $m=12$ datos. La muestra de ajuste va de enero de 2001 a julio de 2023, con $n=271$ observaciones, y la de validación cruzada de agosto de 2023 a julio de 2024.

3.1. Modelo 1

Tabla 6: Parámetros del suavizamiento LOESS y medidas de ajuste del Modelo 1.

Estimaciones efectos estacionales	
i	δ_i
1	0.8438772
2	0.9680340
3	1.0614338
4	0.9852342
5	1.0431641
6	1.0191413
7	1.0185688
8	1.0257722
9	1.0680461
10	1.0450086
11	1.0238045
12	0.8979151
Resumen LOESS lineal	
nep	23
α óptimo según AICC	0.0666031
p (parámetros totales)	34
MSE	15.492
AIC, versión $\exp(C_n^*(p))$	19.028
BIC, versión $\exp(C_n^*(p))$	29.900

Tabla 7. Criterios de Información: $\exp(C_n^*(p))$

Modelo	p	AIC	BIC
Modelo 1	34	19.028473	29.900129
Modelo 2	30	22.472220	33.483019




Figura 10: LOESS sobre la serie desestacionalizada (izquierda) y estacionalidad estimada por el filtro (derecha).

El ajuste queda $\hat{Y}_t = \hat{T}_t \cdot \hat{S}_t$, donde $\hat{T}_t$ es la curva LOESS lineal con span óptimo $\hat{\alpha} = 0.0666$ y $\hat{S}_t$ toma los 12 valores de la Tabla 12 según el mes calendario de t .

El span óptimo $\hat{\alpha} = 0.0666$ es muy pequeño y se traduce en 23 parámetros equivalentes loess. El suavizamiento resultante es casi interpolador: sigue de cerca cada oscilación de la serie desestacionalizada en lugar de representar una tendencia suave. El criterio

AICC premia el ajuste local y termina eligiendo una curva poco parsimoniosa. Eso explica el AIC bajo y anticipa lo que se confirma en los residuos: al absorber estructura que debería quedar en el error, el modelo no la modela de forma explícita. La estacionalidad estimada sí reproduce el patrón observado en los boxplots, con mínimos en enero, cercano a 0.84, y diciembre, cercano a 0.90, y máximos en septiembre, cercano a 1.07, y marzo, cercano a 1.06. En términos multiplicativos, un enero típico está un 16 % por debajo del nivel de tendencia y un septiembre típico un 7 % por encima.

3.2. Modelo 2

Tabla 8. Parámetros estimados en Modelo 2

Parámetros	Estimación	s.e	T_0	$P(t_{241} > T_0)$	Parámetros	Estimación	s.e	T_0	$P(t_{241} > T_0)$
ϕ_1	0,33715	0,05970	5,64753	$4,57 \times 10^{-8}$	β_0	3,60661	0,04123	87,48514	$1,32 \times 10^{-184}$
ϕ_2	0,20151	0,06268	3,21483	0,00148	β_1	0,00597	0,00130	4,59895	$6,86 \times 10^{-6}$
ϕ_3	0,14400	0,06403	2,24895	0,02542	β_2	$-2,17 \times 10^{-5}$	$7,17 \times 10^{-5}$	-0,30218	0,76277
ϕ_4	-0,02403	0,06450	-0,37259	0,70978	β_3	$6,66 \times 10^{-8}$	$2,57 \times 10^{-7}$	0,25914	0,79575
ϕ_5	0,04528	0,06444	0,70280	0,48286	δ_1	-0,06658	0,01320	-5,04476	$8,94 \times 10^{-7}$
ϕ_6	0,08926	0,06405	1,39348	0,16476	δ_2	0,07409	0,01596	4,64244	$5,66 \times 10^{-6}$
ϕ_7	-0,06884	0,06359	-1,08254	0,28009	δ_3	0,17033	0,01671	10,19522	$1,59 \times 10^{-20}$
ϕ_8	-0,04133	0,06345	-0,65135	0,51544	δ_4	0,09394	0,01831	5,13142	$5,92 \times 10^{-7}$
ϕ_9	0,15955	0,06329	2,52092	0,01235	δ_5	0,15380	0,01822	8,44109	$2,96 \times 10^{-15}$
ϕ_{10}	-0,10610	0,06378	-1,66350	0,09751	δ_6	0,13068	0,01720	7,59770	$6,65 \times 10^{-13}$
ϕ_{11}	0,08788	0,06403	1,37260	0,17115	δ_7	0,12366	0,01821	6,79011	$8,66 \times 10^{-11}$
ϕ_{12}	0,06296	0,06403	0,98330	0,32644	δ_8	0,13211	0,01849	7,14600	$1,06 \times 10^{-11}$
ϕ_{13}	0,10373	0,06311	1,64348	0,10159	δ_9	0,17472	0,01689	10,34460	$5,42 \times 10^{-21}$
ϕ_{14}	-0,09173	0,06129	-1,49674	0,13577	δ_{10}	0,15146	0,01607	9,42558	$3,70 \times 10^{-18}$
ϕ_{15}	-0,18855	0,05804	-3,24863	0,00132	δ_{11}	0,13083	0,01324	9,88259	$1,49 \times 10^{-19}$

Con $k = 30$ parámetros y factor de corrección $\exp(\hat{\sigma}_a^2/2) = 1.00137$, la serie ajustada en la escala original es

$$\hat{Y}_t = \exp\left(\hat{\beta}_0 + \hat{\beta}_1 t + \hat{\beta}_2 t^2 + \hat{\beta}_3 t^3 + \sum_{i=1}^{11} \hat{\delta}_i I_i(t) + \hat{E}_t\right) \times 1.00137.$$

En un modelo multiplicativo los coeficientes de las indicadoras se interpretan como $\exp(\hat{\delta}_i) \times 100\%$, que es el porcentaje que representa el nivel del mes i respecto del mes de referencia, diciembre, manteniendo fija la tendencia. Un valor de 90 % significa que ese mes está, en promedio, un 10 % por debajo de diciembre.

Los tests de significancia contrastan $H_0: \beta_j = 0$ frente a $H_1: \beta_j \neq 0$ para cada parámetro, con estadístico $T_0 = \hat{\beta}_j / \text{ee}(\hat{\beta}_j) \sim t_{n-k}$, con $n - k = 241$ grados de libertad, obtenido con `coefstest(modelo2, df = df2)`, y criterio de rechazo cuando el valor p es menor a 0.05.

Tabla 9. Resumen Tests de significancia de parámetros

A. Significancia parámetros estructurales			
Modelo	Significancia grado polinomio (sí, no)	Parámetros significativos en la estacionalidad	Conclusión significancia de la estacionalidad (concluya brevemente)
2	No.	Los 11 indicadores de enero a noviembre, todos con $p \leq 5,66 \times 10^{-6}$	La estacionalidad es altamente significativa. El polinomio podría reducirse a grado 1, ya que los términos cuadrático y cúbico no aportan
B. Significancia parámetros del error estructural			
Modelo	Nombre modelo del error	Parámetros significativos	¿Podría reducirse el modelo en el error? (concluya brevemente)
2	AR(15)	$\phi_1, \phi_2, \phi_3, \phi_9, \phi_{15}$, todos con $p < 0,05$. Los 10 restantes no son significativos	Sí. Solo 5 de los 15 coeficientes resultan significativos, de modo que un AR de subconjunto con los rezagos 1, 2, 3, 9, 15 sería más parsimonioso

3.3. Modelo 3

Modelo a ajustar: ARIMA(1,1,2)(2,1,2)[12]

$(1 - \phi_1 B)(1 - \phi_1 B^{12} - \phi_2 B^{24})(1 - B)(1 - B^{12}) \text{Log}(Y_t) = (1 + \theta_1 B)(1 + \theta_1 B^{12} + \theta_2 B^{24}) E_t$, con $\{E_t\}_{t \in \mathbb{Z}^+}$ un R. $B \sim N(0, \sigma^2)$

Tabla 10. Resumen Tests de significancia de parámetros

Parámetros	Estimación	s.e	T_0	$P(Z > Z_0)$
ϕ_1	-0,14716	0,84094	-0,17499	0,86108
θ_1	-0,49004	0,84686	-0,57866	0,56282
θ_2	-0,09953	0,54722	-0,18188	0,85568
Φ_1	-0,51732	0,18580	-2,78424	0,00537
Φ_2	-0,12149	0,09396	-1,29309	0,19598
Θ_1	-0,23034	0,18046	-1,27642	0,20181
Θ_2	-0,47760	0,16668	-2,86528	0,00417

Solo Φ_1 , con $p = 0,005$, y Θ_2 , con $p = 0,004$, resultan significativos al 5 %. Los parámetros $\phi_1, \theta_1, \theta_2, \Phi_2$ y Θ_1 no lo son. Que 5 de 7 parámetros no aporten indica que el modelo está sobreparametrizado.

3.4. Comparación de los ajustes




Figura 11: Serie observada y ajuste de los tres modelos, en la escala original de los datos. Los modelos 2 y 3 llevan aplicado el factor de corrección lognormal.

Los tres ajustes son visualmente casi indistinguibles: los tres reproducen el nivel, la aceleración desde 2021 y la oscilación estacional mes a mes, incluidos los picos de 2020 a 2022. La comparación gráfica, por sí sola, no permite preferir uno sobre otro, y esa es la primera conclusión que deja la figura.

Mirando de cerca si hay una diferencia de grado. En el Modelo 1 la curva roja tapa la serie observada en casi todo el recorrido, incluidos los primeros años, donde el índice es bajo. En los modelos 2 y 3 la línea negra asoma un poco más, sobre todo antes de 2005 y en los máximos y mínimos de los últimos años. Es el comportamiento esperable: el Modelo 1 se ajusta con un LOESS casi interpolador, mientras que los otros dos imponen una estructura, polinomio con indicadoras en uno y diferenciación con términos ARMA en el otro, y por eso no persiguen cada dato. Que el ajuste sea bueno en la escala original desde el primer año confirma además que el factor de corrección lognormal quedó bien aplicado en los modelos 2 y 3.

3.5. Comparación de las medidas de ajuste

Los criterios de información de los tres modelos se reportan de forma conjunta en la Tabla N de la Sección 6, siguiendo la indicación de la plantilla de reunir en una sola tabla los resultados de la misma naturaleza.

El Modelo 1 obtiene el mejor AIC y el Modelo 3 el mejor BIC. La diferencia se explica por la penalización: el BIC castiga más el número de parámetros, y el SARIMA tiene 7 frente a los 30 del Modelo 2 y los 34 del Modelo 1. Estas medidas por sí solas no bastan para elegir, porque no dicen nada sobre la validez de los supuestos, que se evalúa en la siguiente sección.

Los tres se comparan igual, a pesar de que la Tabla 16 mostró que solo 5 de los 15 coeficientes AR del error del Modelo 2 son significativos: el modelo ajustado es el asignado en la guía, no uno elegido libremente, así que su comparación de AIC/BIC frente a los otros dos sigue siendo válida. La sobreparametrización no invalida el ajuste, solo indica que un AR de subconjunto habría sido más parsimonioso; es información que se retoma en las conclusiones para matizar cualquier preferencia por el Modelo 2 basada únicamente en AIC o BIC.

4. Análisis de residuales y validación de supuestos

En esta sección se determina si el supuesto de que los errores de ajuste son un ruido blanco normal, $E_t \sim \text{RB } N(0, \sigma^2)$, es válido en cada modelo. Sobre los residuos de ajuste se examinan la media cero, $E[E_t] = 0 \forall t$, y la varianza constante, $\text{Var}[E_t] = \sigma^2$, mediante las gráficas de residuales; la incorrelación mediante los tests de la ACF muestral, la PACF muestral y Ljung-Box; y, solo cuando la incorrelación no se rechaza, la normalidad mediante el test de Shapiro-Wilk y la gráfica de probabilidad normal.

Los residuos con los que se trabaja dependen de la escala en que se ajustó cada modelo. En los modelos 2 y 3, ajustados sobre el logaritmo de la serie,

$$\hat{E}_t = \log(Y_t) - \widehat{\log(Y_t)},$$

de modo que están en la escala logarítmica. En el Modelo 1, ajustado sobre la serie sin transformar,

$$\hat{E}_t = Y_t - \hat{Y}_t,$$

y están en la escala original del índice. Por esa razón las magnitudes de los residuos no son comparables entre el Modelo 1 y los otros dos; lo que sí se compara es la forma de los patrones.

Tabla 11. Tabla. Pruebas ACF y PACF para probar ruido blanco, con $n=271$.

Prueba ACF	Prueba PACF
Para $k = 1, 2, \dots, 36$ se prueba de manera individual $H_0: \rho(k) = \text{corr}(E_t, E_{t+k}) = 0$ frente a $H_1: \rho(k) \neq 0$	Para $k = 1, 2, \dots, 36$ se prueba de manera individual $H_0: \phi_{kk} = \text{corr}(E_t, E_{t+k} E_{t+1}, \dots, E_{t+k-1}) = 0$ frente a $H_1: \phi_{kk} \neq 0$

Estadístico de prueba, bajo el supuesto de ruido blanco y de forma aproximada: $\hat{\rho}(k) = \frac{\sum_{t=1}^{n-k} E_t E_{t+k}}{\sum_{t=1}^n \hat{E}_t^2} \sim N(0, 1/271)$	Estadístico de prueba, bajo el supuesto de ruido blanco y de forma aproximada: $\hat{\phi}_{kk} \sim N(0, 1/271)$
Criterio de rechazo: $ \hat{\rho}(k) \geq \frac{2}{\sqrt{271}} = 0.1215$	Criterio de rechazo: $ \hat{\phi}_{kk} \geq \frac{2}{\sqrt{271}} = 0.1215$

Tabla 12. Test de Ljung-Box sobre los residuos de ajuste de los tres modelos

Con $\rho(k) = \text{corr}(E_t, E_{t+k})$ $H_0: \rho(1) = \rho(2) = \dots = \rho(m) = 0$ H_1: al menos un $\rho(k) \neq 0$, con $k = 1, 2, \dots, m$ Estadístico de prueba: $Q_{LB} = n(n+2) \sum_{k=1}^m \frac{\hat{\rho}^2(k)}{n-k} \sim \chi_m^2$ de forma aproxim Criterio de rechazo con valor P: se rechaza H_0 si $P(\chi_m^2 > Q_{LB}) < 0.05$									
	Modelo 1			Modelo 2			Modelo 3		
m	Q_{LB}	gl	$P(\chi_m^2 > Q_{LB})$	Q_{LB}	gl	$P(\chi_m^2 > Q_{LB})$	Q_{LB}	gl	$P(\chi_m^2 > Q_{LB})$
6	22.99446	6	0.00080	0.62434	6	0.99598	2.05200	6	0.91485
12	65.83337	12	0.00000	1.20456	12	0.99996	14.03898	12	0.29823
18	96.98677	18	0.00000	7.29677	18	0.98738	20.49574	18	0.30561
24	119.10319	24	0.00000	19.25248	24	0.73839	29.08710	24	0.21687
30	128.98736	30	0.00000	21.85012	30	0.85944	32.49252	30	0.34498
36	138.68665	36	0.00000	33.87630	36	0.56998	41.29538	36	0.25028




Figura 12: Residuales vs tiempo. (a) Modelo 1; (b) Modelo 2; (c) Modelo 3




Figura 13: Residuales vs valores ajustados. (a) Modelo 1; (b) Modelo 2; (c) Modelo 3




Figura 14: ACF residuos de ajuste. (a) Modelo 1; (b) Modelo 2; (c) Modelo 3




Figura 15: PACF residuos de ajuste. (a) Modelo 1; (b) Modelo 2; (c) Modelo 3




Figura 16: Gráficas de normalidad. (a) Modelo 2; (b) Modelo 3

Tabla 13. Resultados evaluación supuestos para errores de ajuste

Modelo	Varianza cte (sí, no)	Media en cero (sí, no)	Rechazos en ACF (k=)	Rechazos en PACF (k=)	Rechazos en Ljung-Box (m=)	Normalidad ^(*) (sí, no, NA)	¿Modelo estadísticamente válido? (justifique brevemente)
1	No	Sí	K = 4, 6, 7, 11, 12, 13, 19 y 23	k = 4, 6, 7, 8, 10, 13 y 24	Rechazo para todo m	NA	No, debido a que hay evidencia fuerte en contra de la varianza constante, pues la dispersión crece con el nivel de la serie. Además, la ACF y la PACF exhiben patrón y no rezagos aislados, y el Ljung-Box rechaza en todo m. Se rechaza RB y no se valida el supuesto de normalidad.
2	Sí	Sí	k = 18 y 30	k = 19, 31 y 33	No hay rechazos	No	No, debido a que se rechaza el supuesto de normalidad ($W = 0,97122$, $P = 2,84 \times 10^{-5}$). Se cumplen $E[at] = 0 \forall t$ y la varianza constante y, aunque se detectan correlaciones en $k = 18$ y 30 , se deben a Error tipo I, por lo que sí se valida RB.
3	Sí	Sí	k = 19	k = 9 y 31	No hay rechazos	No	No, porque se rechaza la normalidad ($W = 0,97916$, $P = 5,35 \times 10^{-4}$). Se cumplen $E[Et] = 0 \forall t$ y varianza constante y, aunque hay rechazos aislados en la ACF ($k = 19$) y en la PACF ($k = 9$ y 31), se atribuyen a error tipo I, por lo que sí se valida RB.

(*) Evalúe sólo si no se detectan correlaciones o correlaciones parciales significativas para el error de ajuste; coloque NA si no se debe realizar el test

Tabla 14. Resumen test Shapiro-Wilk para Et

Modelo	W	valor.p
Modelo 1	NA	NA
Modelo 2	0.971225	0.000028
Modelo 3	0.979161	0.000535

5. Pronósticos para la validación cruzada

5.1. Modelo 1

Con origen en $n = 271$ y horizonte $L = 1, \dots, 12$, el pronóstico puntual es $\hat{Y}_{271+L}(L) = \hat{T}_{271+L} \cdot \hat{S}_{271+L}$, donde $\hat{T}_{271+L}$ es la extrapolación de la tendencia LOESS y $\hat{S}_{271+L}$ el factor estacional del mes correspondiente.

El pronóstico puntual de enero de 2024 es de aproximadamente 137.1, lo que significa que se espera que la producción nominal de ese mes sea cerca de 1.37 veces el promedio mensual de 2018. Su intervalo de predicción del 95 % va de 127.0 a 147.1: con 95 % de confianza el índice observado cae en ese rango.

5.2. Modelo 2

Con origen $n = 271$, $\hat{Y}_{271}(L) \approx \exp(\log \widehat{Y}_{271}(L)) \times \exp(\hat{\sigma}_a^2/2)$, y los límites del intervalo de predicción se trasladan a la escala original exponenciando y multiplicando por el mismo factor.

5.3. Modelo 3

El procedimiento es el mismo del Modelo 2, con $\hat{Y}_{271}(L) \approx \exp(\log \widehat{Y}_{271}(L)) \times \exp(\hat{\sigma}^2/2)$. Siguiendo la indicación de la guía, no se reporta la ecuación de pronóstico porque es algebraicamente muy extensa.

Tabla 15. Pronósticos puntuales e intervalos de predicción del 95 % de los modelos 1, 2 y 3.

Modelo 1				Modelo 2				Modelo 3			
Mes	Pronóstico	Límite inferior	Límite superior	Mes	Pronóstico	Límite inferior	Límite superior	Mes	Pronóstico	Límite inferior	Límite superior
2023/8	168.93	159.85	178.02	2023/8	171.18	154.49	189.69	2023/8	175.18	156.91	195.57
2023/9	175.50	165.99	185.01	2023/9	179.43	161.01	199.95	2023/9	181.62	161.54	204.19
2023/10	171.28	161.49	181.08	2023/10	172.31	153.89	192.93	2023/10	180.33	159.37	204.04
2023/11	167.34	157.24	177.44	2023/11	170.60	151.66	191.90	2023/11	178.87	157.11	203.64
2023/12	146.33	136.39	156.28	2023/12	151.61	134.55	170.83	2023/12	157.30	137.36	180.14
2024/1	137.09	127.05	147.14	2024/1	139.83	123.85	157.86	2024/1	146.78	127.46	169.04
2024/2	156.74	145.63	167.85	2024/2	164.27	145.10	185.97	2024/2	167.79	144.91	194.27
2024/3	171.27	159.07	183.48	2024/3	179.06	158.06	202.85	2024/3	183.32	157.51	213.36
2024/4	158.41	146.22	170.60	2024/4	165.52	146.05	187.59	2024/4	169.49	144.89	198.26
2024/5	167.11	153.91	180.30	2024/5	179.87	158.30	204.38	2024/5	173.46	147.57	203.90
2024/6	162.64	149.07	176.22	2024/6	176.14	154.99	200.17	2024/6	177.40	150.21	209.52
2024/7	161.92	147.76	176.08	2024/7	176.31	154.92	200.65	2024/7	180.85	152.43	214.58

5.4 Precisión de los pronósticos y comparación

Las medidas de precisión puntual y por intervalos de los tres modelos se reportan de forma conjunta en la Tabla N de la Sección 6.

Las medidas de precisión puntual se interpretan sobre las unidades del índice. El MAE indica en cuántos puntos se desvía el pronóstico del valor observado, en promedio. El RMSE es mayor que el MAE en los tres modelos, señal de que hay meses con errores más grandes que reciben más penalización. El MAPE expresa ese error como porcentaje del valor real, y es la medida más comparable entre modelos por ser adimensional.

El Modelo 2 obtiene el mejor MAPE, 2.98 %, y el mejor RMSE. El Modelo 3 queda en el medio, con MAPE de 3.75 %, y el Modelo 1 último con 4.03 %.

En cuanto a los intervalos, los tres modelos alcanzan cobertura del 100 %: los 12 valores reales cayeron dentro de sus respectivos intervalos. La diferencia está en la amplitud. Los del Modelo 1 son los más angostos, con 22.49 puntos de amplitud media, seguidos por los del Modelo 2 con 40.66 y los del Modelo 3 con 49.44. Como todos tienen cobertura completa, el score promedio ordena igual que la amplitud y favorece al Modelo 1.

Para el horizonte de 12 meses evaluado, el Modelo 2 pronostica mejor en términos puntuales. El Modelo 1 obtiene mejores intervalos, pero ese resultado tiene una salvedad importante: sus intervalos se construyen bajo el supuesto de errores no correlacionados, que ese modelo no cumple, así que su ventaja aparente no es confiable. Entre los dos modelos cuyos residuos sí son ruido blanco, el Modelo 2 domina tanto en precisión puntual como en amplitud y score.

6. Comparación de los tres modelos y selección del mejor

Tabla 16. Ecuaciones teóricas de los 3 modelos

Modelo 1: Descomposición multiplicativa con tendencia local LOESS lineal (criterio AICC) $Y_t = T_t \cdot S_t \cdot E_t, \quad t = 1, \dots, n = 271$ $\{E_t\}$ con $E[E_t] = 1$ y $\text{Var}[E_t] = \sigma^2$, no correlacionados. T_t es la tendencia estimada por regresión LOESS de grado 1 sobre la serie desestacionalizada, con span óptimo elegido por AICC. S_t es el factor estacional del mes calendario de t, obtenido del filtro de descomposición multiplicativa, con $\prod_{j=1}^{12} S_j = 1$. El ajuste se hace en la escala original, sin corrección lognormal.
Modelo 2: Regresión log-polinómica de grado 3 con estacionalidad de indicadoras y error estructural AR(15) $\log(Y_t) = \beta_0 + \beta_1 t + \beta_2 t^2 + \beta_3 t^3 + \sum_{i=1}^{11} \delta_i I_i(t) + E_t, \quad \Phi(B)E_t = a_t$ $\Phi(B) = 1 - \phi_1 B - \phi_2 B^2 - \dots - \phi_{15} B^{15}$, con $\{a_t\}$ un RB $\sim N(0, \sigma_a^2)$. $I_i(t) = 1$ si el mes de t es el mes i, para $i = 1, \dots, 11$ (enero a noviembre), y 0 en otro caso; diciembre es el mes de referencia. Los valores ajustados en la escala original requieren el factor de corrección lognormal $\exp(\hat{\sigma}^2/2)$.
Modelo 3: SARIMA(1,1,2)(2,1,2)[12] sobre $\log(Y_t)$, sin deriva $(1 - \phi_1 B)(1 - \phi_1 B^{12} - \phi_2 B^{24})(1 - B)(1 - B^{12}) \log(Y_t) = (1 + \theta_1 B + \theta_2 B^2)(1 + \theta_1 B^{12} + \theta_2 B^{24}) E_t$ $\{E_t\}, E_t \in \mathbb{Z}^+$ un RB $\sim N(0, \sigma^2)$. No lleva deriva porque se usan las dos diferencias, $d = D = 1$. Los valores ajustados en la escala original requieren el factor de corrección lognormal $\exp(\hat{\sigma}^2/2)$.

Tabla 17. Precisión de los Pronósticos puntuales y de los I.P del 95%

Modelo	MAE	MAPE(%)	RMSE	Amplitud*	Cobertura(%)	Score Promedio I.P	AIC	BIC
Modelo 1	6.661	4.032	7.302	22.486	100	22.486	19.028	29.900
Modelo 2	4.942	2.983	6.467	40.658	100	40.658	22.472	33.483
Modelo 3	6.249	3.746	8.311	49.436	100	49.436	24.427	26.809




Figura 17. Pronósticos puntuales de los tres modelos frente a los valores reales de la muestra de validación.

Tabla 18. Resumen de la validación de supuestos sobre los errores de ajuste de los tres modelos.

Modelo	Error de ajuste	Residuales	Escala	Validez RB	Validez normalidad (*)	¿Estadísticamente válido?
Modelo 1 · Local DLL(AICC)	E_t	$\hat{E}_t = Y_t - \hat{Y}_t$	Original	No	NA	No
Modelo 2 · Global con error ARMA	a_t	$\hat{a}_t = \log(Y_t) - \log(\hat{Y}_t)$	Logarítmica	Sí	No	No
Modelo 3 · SARIMA	E_t	$\hat{E}_t = \log(Y_t) - \log(\hat{Y}_t)$	Logarítmica	Sí	No	No

(*) La normalidad solo se evalúa cuando no se detectan autocorrelaciones ni autocorrelaciones parciales significativas en el error de ajuste; se indica NA cuando no procede realizar el test.

Se recomienda modelar esta serie con el Modelo 2, la regresión log-polinómica estacional con error AR(15). El Modelo 1 queda descartado de entrada: sus residuos no son ruido blanco y su varianza no es constante, de modo que la inferencia que sustenta sus intervalos de predicción no es válida y su ventaja aparente en AIC y en amplitud de los intervalos no resulta confiable. Entre los dos modelos cuyos errores de ajuste sí son ruido blanco, el Modelo 2 domina en pronóstico: MAPE de 2.98 % frente a 3.75 % del Modelo 3, mejor MAE, mejor RMSE e intervalos más angostos con la misma cobertura del 100 %. El Modelo 3 solo aventaja en BIC, y lo hace por su menor número de parámetros, no por calidad de ajuste ni de pronóstico; además, 5 de sus 7 coeficientes no resultan significativos. Conviene señalar que ninguno de los tres modelos es estadísticamente válido en sentido estricto, pues la normalidad se rechaza en los Modelos 2 y 3 y el supuesto de ruido blanco falla en el Modelo 1.

La recomendación se sostiene, sobre todo, en cómo se comporta la serie en el tiempo. Se trata de un índice nominal con tendencia creciente y suave, con una aceleración marcada desde 2021, y con una estacionalidad determinística que se mantiene prácticamente constante a lo largo de los 23 años observados. Una modelación global captura esa dinámica de forma directa: representa la tendencia con un polinomio y la estacionalidad con indicadores fijas, y deja al error autorregresivo únicamente la dependencia de corto plazo que queda sin explicar. El SARIMA, en cambio, no estima esas componentes, sino que las elimina por diferenciación, y pierde así la información estructural que en esta serie es justamente la más estable y la más predecible. Por esta razón la modelación de regresión global con error ARMA se aproxima mejor a la dinámica de la serie que la modelación ARIMA.

7. Conclusiones

Finalmente se comparan los tres modelos.

Para cerrar el análisis, la Tabla 19 y la Tabla 20 resumen y comparan entre sí los tres modelos ajustados a la serie: el modelo Global, el modelo Local, el modelo Global con error ARMA y el modelo SARIMA.

Tabla 19. Resumen criterios de información, medidas de precisión de pronóstico puntual y por intervalos para mejores modelos.

Modelo	Criterios de información			Pronóstico Puntual			Intervalos		
	p	AIC	BIC	MAE	MAPE(%)	RMSE	Amplitud	Cobertura (%)	Score
Local	34	19.028	29.900	6.661	4.032	7.302	22.486	100.00	22.486
Global con error ARMA	30	22.472	33.483	4.942	2.983	6.467	40.658	100.00	40.658
SARIMA	7	24.427	26.809	6.249	3.746	8.311	49.436	100.00	49.436

Tabla 20. Resumen validación de supuestos para mejores modelos propuestos para la serie.

Modelo	Errores de ajuste	Residuales	Validez RB	Validez Normalidad	Estadísticamente válido
Local	E_t	$E_t = Y_t - \hat{Y}_t$	No	NA	No
Global con error ARMA	a_t	$\hat{a}_t = Y_t - \hat{Y}_t$	Sí	No	No
SARIMA	E_t	$E_t = Y_t - \hat{Y}_t$	Sí	No	No

El análisis descriptivo mostró que la serie del índice de producción nominal de “Fabricación de otros productos químicos” presenta tendencia creciente con varianza heterocedástica, lo que llevó a trabajar sobre el logaritmo de la serie; su componente estacional es

prácticamente constante en el tiempo, con mínimos en enero y diciembre y máximos entre marzo y septiembre. El test HEGY confirmó la necesidad de aplicar una diferencia regular ($d=1$) y una diferencia estacional ($D=1$) para alcanzar un proceso ergódico. Sobre esta base se ajustaron tres modelos con distinta filosofía: el Modelo 1 (suavizamiento LOESS más estacionalidad global), el Modelo 2 (tendencia polinómica con indicadores estacionales y error autorregresivo) y el Modelo 3 (SARIMA(1,1,2)(2,1,2)[12]). En el ajuste, los tres modelos replicaron adecuadamente la trayectoria de la serie, entre el Modelo 1 y el Modelo 3 la reproducción del comportamiento observado fue algo más cercana, aunque el Modelo 2 no quedó lejos de ninguno de los dos. En el pronóstico de los últimos $m=12$ meses, el Modelo 2 resultó el más preciso, con el mejor MAPE (2.98 %), el mejor MAE (4.94) y el mejor RMSE (6.47), seguido del Modelo 3 (MAPE 3.75 %) y del Modelo 1 (MAPE 4.03 %); los tres alcanzaron cobertura del 100 % en sus intervalos del 95 %, aunque los del Modelo 1 fueron los más angostos.

La principal dificultad del proceso de modelación estuvo en la validación de supuestos sobre los errores de ajuste. Casi ningún modelo logró de forma directa que sus residuos fueran ruido blanco: en la mayoría de los casos siempre aparecía algún rezago k significativo en la ACF o la PACF, y cuando finalmente se alcanzaba la incorrelación, el supuesto de normalidad fallaba. Así ocurrió con los Modelos 2 y 3, cuyos errores sí resultaron ruido blanco pero no normales (Shapiro-Wilk: $W=0.971$, $p=2.8 \times 10^{-5}$ para el Modelo 2, y $W=0.979$, $p=5.35 \times 10^{-4}$ para el Modelo 3); el Modelo 1, por su parte, no logró superar ni siquiera la prueba de ruido blanco, pues su varianza no es constante y el Ljung-Box rechazó la incorrelación en todos los rezagos evaluados. En sentido estricto, ninguno de los tres modelos resultó estadísticamente válido según los criterios de la Tabla 20.

El Modelo 2 capturó adecuadamente la dinámica de la serie: su tendencia polinómica junto con las indicadoras estacionales reproducen bien el nivel, la aceleración de 2021-2023 y el patrón estacional mensual, y sus pronósticos puntuales están entre los más cercanos a los valores observados en el período de validación, con intervalos que cubren el 100% de las observaciones reales, por lo que los pronósticos resultan realistas y confiables para el horizonte evaluado. Sin embargo, el modelo tiene limitaciones importantes: no cumple el supuesto de normalidad de los errores, lo que afecta la validez teórica de los intervalos de predicción calculados bajo ese supuesto; y su especificación resultó sobreparametrizada, pues solo 5 de los 15 coeficientes autorregresivos del error resultaron significativos, lo que indica que un modelo más parsimonioso (por ejemplo, un AR de subconjunto con los rezagos 1, 2, 3, 9 y 15) podría alcanzar un desempeño similar con menos parámetros. Estas limitaciones deben tenerse presentes al utilizar el modelo para fines de pronóstico más allá del pronóstico de validación cruzada.¹

Referencias

- [1] DANE (2020), "Metodología General Encuesta Mensual Manufacturera con Enfoque Territorial - EMMET", DIMPE, Bogotá.
- [2] DANE (2022), "Clasificación Industrial Internacional Uniforme de todas las Actividades Económicas, Revisión 4 adaptada para Colombia: CIIU Rev. 4 A.C.", Bogotá.
- [3] DANE (2024), "EMMET. Boletín técnico, julio de 2024", Bogotá.
- [4] DANE (2024), "Anexos EMMET Total Nacional, julio de 2024", archivo anex-EMMET-TotalNacional-jul2024-Fabricacion de Otros Productos Quimicos.csv.
- [5] Bowerman, O'Connell y Koehler (2009), Pronósticos, Series de Tiempo y Regresión, 4 ed., CENGAGE.
- Cryer y Chan (2008), Time Series Analysis With Applications in R, Springer.
- [6] González, N. G. (2013), Notas de Clase Estadística III 3009137, Escuela de Estadística, UNAL Medellín DANE (2020), "Metodología General Encuesta Mensual Manufacturera con Enfoque Territorial - EMMET", DIMPE, Bogotá.